

Fundamentos de IA Productiva

MÓDULO 6 DE 7

Agentes: de Responder a Actuar

Le das un **objetivo** y **herramientas**,
y decide los pasos por sí mismo. Ahí empieza —y termina— su poder.

1. Qué es un agente (y qué no)
2. Cómo trabaja: el bucle agéntico
3. Autonomía y el humano en el bucle
4. Varios agentes juntos
5. Riesgos, límites y criterio

Navega con



o los botones de abajo

1

TEMA 1

Qué es un agente (y qué no)

Aquel caso del M5 en que la IA revisaba tu correo y creaba eventos... era tu primer agente.

Cambia quién decide los pasos

	CHAT (ASISTENTE)	AGENTE
Tú das	Una instrucción por turno	Un objetivo
Decide los pasos	Tú	El modelo
Cómo avanza	Un intercambio a la vez	En bucle , encadenando
Tu papel	Conductor paso a paso	Supervisor del objetivo

ANALOGÍA · EL TAXI Y EL GPS

Un chat es el copiloto al que preguntas "¿giro aquí?". Un agente es el taxista al que das el **destino** y conduce solo. Ganas en no dictar cada giro; el riesgo es que si se equivoca de ruta, avanza antes de que lo notes. Por eso sigues mirando el mapa.

El lazo de vuelta lo cambia todo



Lo que lo hace un agente es que **mira el resultado de su propia acción** y ajusta. Un chat de un turno no puede recuperarse de un error; un agente que observa, sí. Esa auto-corrección es su fuerza — y por qué a veces persigue una madriguera.

Las cuatro piezas de todo agente

PIEZA	QUÉ ES	EN LA IMPRENTA
Objetivo	La meta que persigue (la pones tú)	"Prepara las cotizaciones de hoy"
Cerebro	El modelo que razona y decide	El LLM (Opus/Sonnet, M3)
Herramientas	Lo que puede <i>hacer</i>	Consultar, calcular, enviar (MCP, M3)
Memoria	Lo que recuerda al trabajar	Qué ya hizo y qué falta (M4)

Prueba del "¿es de verdad un agente?": ¿están las cuatro piezas? Muchos "agentes" del marketing son un chat con buen prompt. Saber distinguirlo evita pagar por autonomía que no existe.

2

TEMA 2

Cómo trabaja un agente

Objetivo, herramientas, memoria y saber cuándo parar.

"Prepara una cotización por cada pedido de hoy"

1. PERCIBIR

Consulta el correo → 3 pedidos sin confirmar.
2. PLANIFICAR

"Por cada uno: extraer → tarifa → calcular → redactar."
3. ACTUAR

Abre el pedido 1, extrae cantidades y papel.
4. OBSERVAR

"Falta el gramaje" → decide consultar el tarifario.
5. ACTUAR

Consulta tarifario, calcula precio (ejec. de código).
6. OBSERVAR

"Cotización 1 lista, quedan 2" → vuelve al paso 3.
- ...

y al terminar, te las presenta para revisar (no envía).

El agente **descompone** el objetivo (como los hitos del M4, pero él), **elige** la herramienta según lo que observa, y **se detiene** antes de una acción con consecuencias.

Las manos y la libreta del agente

Herramientas = alcance real

Buscar web · ejecutar código · connectors (correo, agenda, datos) · leer docs/imágenes. Sin ellas es un cerebro en un frasco.

Memoria = no empezar de cero

Recuerda qué hizo y qué falta mientras trabaja. Es el "colaborador amnésico" del M4, pero dentro de una tarea autónoma.

LA DISTINCIÓN CLAVE (M3)

Herramientas que **leen** (bajo riesgo) vs. que **actúan** (enviar, borrar). El inventario de herramientas de un agente es su **mapa de riesgo**.

2.4 · CRITERIOS DE PARADA

Un agente tiene que saber cuándo parar

- **Cumplió el objetivo** (contra criterios claros, como un specdoc del M4).
- **Llegó a un punto que requiere un humano** (acción irreversible, ambigüedad).
- **Se topó con un muro** y tiene la sensatez de **pedir ayuda, no inventar**.
- **Agotó un límite** que le pusiste: pasos, tiempo o presupuesto.

EL FALLO CLÁSICO

Un mal agente que no encuentra un dato **alucina uno** (M1) y sigue, propagando el error. "Si no lo encuentras, para y pregúntame" es el freno de emergencia. Un buen agente sabe decir "no pude".

3

TEMA 3

Autonomía y el humano en el bucle

La autonomía es un dial que gradúas según el riesgo, no un interruptor.

De copiloto a autónomo

NIVEL	CÓMO FUNCIONA	EJEMPLO
Copiloto	Sugiere; tú ejecutas	Propone la cotización; tú envías
Supervisado	Actúa, pide confirmación en lo que importa	Envía tras tu "ok" en cada correo
Semi-autónomo	Hace la tarea y la presenta al final	Deja los 3 borradores; apruebas el lote
Autónomo	De principio a fin sin intervención	Envía solo (raro y arriesgado)

REGLA DEL DIAL

Reversible y bajo riesgo → más autonomía. Irreversible o costoso → cerca de copiloto/supervisado. **Empieza con poca autonomía y súbela cuando el agente se la gane.**

Cuándo debe pedir permiso

PIDE PERMISO ANTES DE

Enviar comunicaciones · **gastar** dinero · **borrar/sobrescribir** · cualquier acción difícil de deshacer.

PUEDE IR SOLO EN

Leer · buscar · calcular · redactar un borrador que tú revisarás. Lo reversible.

La asimetría (M3): leer es barato de equivocarse; actuar no. El checkpoint humano es tu cinturón de seguridad — como el cajero que confirma una transferencia grande, no falta de confianza.

Tareas buenas y malas para delegar

Buenas

Repetitivas de varios pasos con receta clara · verificables al final · errores reversibles o con checkpoint · te comen tiempo mecánico.

Malas (o máxima supervisión)

Una decisión de alto criterio · acciones irreversibles sin control · objetivos vagos · datos muy sensibles poco supervisados.

Regla: si puedes escribirla como **receta con pasos y un punto de revisión**, es candidata a agente. Si es "usa tu mejor juicio", quédate en chat. Un agente automatiza *procesos*, no *criterio*.

4

TEMA 4

Varios agentes trabajando juntos

Un equipo de especialistas en vez de un empleado que hace de todo.

Divide y coordina



Cada subagente tiene un objetivo **estrecho** y un contexto más limpio (menos context rot, M2), y es más fácil de verificar. El orquestador no hace el trabajo fino: coordina.

4.3 · CUÁNDO NO COMPLICARSE

La trampa del organigrama

ANALOGÍA

Montar tres agentes para lo que un buen prompt resuelve es contratar un equipo de cinco para responder un correo. Cada agente extra añade coordinación, latencia, costo y puntos de fallo.

Empieza con lo más simple que funcione: un chat → luego un agente → y solo si hace falta, varios. La sofisticación la justifica la tarea, no lo impresionante que suena. "Menos y mejor" otra vez (M2, M4).

5

TEMA 5

Riesgos, límites y criterio

La autonomía multiplica las consecuencias de cada debilidad.

Un error temprano se propaga y se amplifica

Paso 1: lee mal una cifra (error pequeño)
Paso 2: calcula el precio con esa cifra → precio malo
Paso 3: redacta la cotización con él → documento malo
Paso 4: (si tuviera autonomía) la envía → error con el cliente

Un chat comete un error y ahí queda; un agente **construye sobre su propio error**. Por eso los puntos de verificación importan más — y deben estar **temprano**. Revisar solo el final es revisar un edificio con cimientos torcidos.

Lo que la autonomía cuesta

Costo y velocidad: diez pasos = diez+ llamadas al modelo. Más lento y más caro que un chat. Y un agente perdido quema pasos sin llegar a nada.

Seguridad (M3, elevada): mínimo privilegio (solo las herramientas necesarias) · inyección de prompt indirecta (contenido que lee y podría obedecer) · nunca encadenar sin control *leer fuentes no confiables* con *actuar*.

La pregunta no es "¿puedo con un agente?", sino "¿**vale la pena?**".

La autonomía delega la ejecución, no la responsabilidad

PRUEBA DE LA DEFENSA · VERSIÓN AGENTE (M4)

Antes de subir la autonomía: *si actúa solo y se equivoca, ¿puedo detectarlo y arreglarlo a tiempo, y responder por lo que hizo?* Si es no, baja el dial hasta que sea sí.

Si un agente envía una cotización con un error, el cliente no acepta "lo hizo la IA". Un agente es un colaborador al que **diriges y verificas** — el principio de todo el curso, con un colaborador que ahora tiene manos y va más rápido que tú.

Los 5 temas, de un vistazo

#	TEMA	IDEA CENTRAL	PARA LLEVAR
1	Qué es un agente	Le das un objetivo; decide los pasos en bucle	Cuatro piezas: objetivo, cerebro, herramientas, memoria
2	Cómo trabaja	Percibir → planificar → actuar → observar	Herramientas = mapa de riesgo; que sepa parar
3	Autonomía	Un dial según el riesgo, no un interruptor	Human-in-the-loop antes de lo irreversible
4	Multi-agente	Equipo de especialistas + orquestador	Empieza simple; no sobre-diseñes
5	Riesgos	La autonomía amplifica errores y consecuencias	El responsable sigues siendo tú