

Fundamentos de IA Productiva

MÓDULO 7 DE 7 · CIERRE DEL CURSO

Criterio y Uso Sostenible

Las capacidades de la IA seguirán creciendo.

Lo que no escala solo es **tu criterio**.

1. Detectar lo plausible pero incorrecto
2. Sesgos y cómo compensarlos
3. Privacidad y datos sensibles
4. Mantenerse actualizado sin volverse loco

Navega con



o los botones de abajo

EL MÓDULO QUE CIERRA EL CÍRCULO

"Esto se trata a fondo en el Módulo 7"

Durante todo el curso fuimos dejando esa frase pendiente. Llegó el momento: los cuatro hilos sueltos —el error que suena bien, los sesgos, la privacidad y no quedarse atrás— se convierten en lo único que de verdad te llevas.

M1 predice, no sabe	M2 hablarle y evaluar	M3 herramientas que tapan agujeros
M4 método sin deuda	M5 el abanico de lo posible	M6 cuando actúa sola

LA TESIS DEL CURSO

Todos esos módulos apuntaban al mismo sitio: **tú sigues siendo el responsable**. El criterio es lo único que no queda obsoleto en tres meses.

1

TEMA 1

Detectar lo plausible pero incorrecto

Tu instinto de "esto suena raro" funciona con humanos. Aquí no te sirve.

El error y el acierto se producen igual

LA CLAVE DE TODO

Cuando acierta, produce texto fluido y seguro. Cuando se equivoca, produce texto **igual de fluido y seguro**. No hay diferencia de tono entre una verdad y una alucinación.

Con una persona, la duda se nota: titubea, dice "creo que". El modelo puede inventar una cláusula o una cifra con la misma prosa impecable. Y cuanto mejor escrito está algo, más tendemos a creerlo — la **trampa de la fluidez** (M4), ahora como problema central.

Los modelos modernos están **mejor calibrados** (dicen más "no estoy seguro"). Es una mejora real, pero no es garantía: **la ausencia de duda no es evidencia de acierto**.

Las siete señales de alarma

#	SEÑAL	POR QUÉ FALLA AHÍ
1	Datos muy específicos (cifras, fechas, leyes)	Lo específico se rellena con lo más probable
2	Fuentes y citas	Puede inventar títulos, autores o URLs
3	Posterior a su fecha de corte	No lo tiene; si no busca, improvisa
4	Aritmética y conteos	No calcula: predice el texto del resultado
5	Nichos muy especializados	Poco material → más relleno plausible
6	Cuando le insistes	Tiende a ceder aunque tuviera razón
7	Premisa falsa	Explica algo falso que <i>tú</i> diste por cierto

TRUCO PARA LA SEÑAL 7

En vez de "*¿por qué pasa X?*", pregunta "**¿pasa X? Si es así, ¿por qué?**". Le das permiso explícito para contradecirte.

Siete formas de comprobar

- **Pide la fuente y ábrela** — la cita es para que vayas al original.
 - **Ancla al documento** — dale el material; es mejor leyendo que recordando.
 - **Que calcule de verdad** — ejecución de código para todo número (M3).
 - **Pregunta al revés** — "¿qué razones hay para pensar que esto está mal?"
-
- **Pide nivel de confianza** — "marca qué es seguro, estimado o no verificable".
 - **Triangula** — pregunta de otra forma en un chat nuevo, sin el contexto previo.
 - **Prueba de la defensa** (M4) — ¿lo defenderías sin la IA delante?

¿Qué pasa si esto está mal y no me doy cuenta?

RIESGO	EJEMPLO	CUÁNTO VERIFICAR
Bajo	Lluvia de ideas, borrador para ti	Casi nada: si sirve, sirve
Medio	Correo interno, resumen para el equipo	Lectura crítica; comprueba datos
Alto	Propuesta a cliente, cifras, contenido público	Cada dato; fuentes abiertas
Crítico	Contrato, impuestos, salud, nómina	Verificación humana experta obligatoria

Verificarlo todo es tan poco práctico como no verificar nada. Si la respuesta es "pierdo un cliente" o "pago una multa", la IA te dio un **borrador**, no una respuesta.

2

TEMA 2

Sesgos y cómo compensarlos

Un sesgo es una desviación **sistemática** — y por eso mismo, compensable.

Dos orígenes, dos efectos

Del corpus de entrenamiento

Hereda lo que hay en el texto del mundo. Si ciertos idiomas, países o perspectivas están sobrerrepresentados, el modelo refleja ese desequilibrio.

Del ajuste con humanos (RLHF)

Se le entrena para dar respuestas que la gente califica como buenas. Efecto secundario: aprende a ser **agradable** — y agradable $\neq$ correcto.

"Sesgo" no significa mala intención ni postura política: significa **desviación sistemática**. Como es sistemática, se corrige — igual que un instrumento que mide siempre dos grados de más.

Seis sesgos del día a día

- **Complacencia** (el más importante) — tiende a darte la razón y a ceder si le llevas la contraria. *Es el enemigo del criterio: si buscas validación, la obtendrás.*
- **Confirmación por cómo preguntas** — "dame argumentos para X" te dará argumentos para X, aunque X sea mala idea.
- **Cultural y lingüístico** — dominado por contenido en inglés; puede errar en normativas, costumbres y precios locales.
- **Homogeneización** — tiende al consejo promedio y a la idea más obvia.
- **Posición y recencia** — atiende más al principio y al final que al medio (context rot, M2).
- **Esteretipos** — puede reproducir asociaciones frecuentes al generar personas, roles o imágenes.

Casi todo se corrige con cómo preguntas

SESGO	CÓMO LO COMPENSAS
Complacencia	"Critica mi idea", "¿en qué estoy equivocado?"
Confirmación	"Argumenta a favor y en contra con la misma fuerza"
Cultural / local	Da tu contexto: país, sector, normativa, moneda
Homogeneización	"Dame 10 opciones, incluyendo 3 poco convencionales"
Posición	Lo crítico al principio o al final; divide lo largo

LA TÉCNICA MÁS RENTABLE DEL MÓDULO

En vez de "*¿qué te parece mi plan?*" (invita a la complacencia), usa **"encuentra los tres puntos más débiles de mi plan y explica cómo fallarían"**. Cambias validación por información útil. Ponlo en las instrucciones de tu Proyecto (M3) y lo tienes siempre activo.



TEMA 3

Privacidad y datos sensibles

No estás escribiendo en un cuaderno privado: estás enviando información a un tercero.

Depende del producto y del plan

- **Retención** — cuánto tiempo se guardan tus conversaciones.
- **Uso para entrenamiento** — suele haber diferencias importantes entre planes de **consumidor** y de **empresa/API**.
- **Quién accede** — revisión de seguridad, administradores de tu organización.
- **Controles** — historial desactivable, borrado, retención configurable.

LA RECOMENDACIÓN QUE NO CADUCA

Lee la política del plan concreto que usas, y revísala de vez en cuando. Y si trabajas en una organización: ¿existe una política interna de uso de IA? Si no, esa conversación vale la pena iniciarla.

La lista corta

NUNCA	Credenciales y secretos (si se te escapa una, rótala) · datos personales de terceros · información bajo NDA o secreto comercial · datos regulados (salud, bancarios, menores).
CON CUIDADO	Documentos internos completos · código propietario crítico · grabaciones de reuniones donde los demás no consintieron.
LA REGLA DE LA PANTALLA COMPARTIDA	Antes de enviar: <i>"¿me sentiría cómodo si esto apareciera proyectado en una reunión?"</i> Si la respuesta es no, anonimízalo. Imperfecta, pero atrapa casi todos los errores graves.

Minimización de datos

La reacción exagerada —"entonces no uso IA para nada de trabajo"— te deja fuera de todo el valor del curso. La postura útil: **trabajar con datos, desacoplados de las personas**.

- **Anonimiza y sustituye** — "Cliente A", importes redondeados. Casi nunca necesita los nombres reales.
- **Manda el extracto, no el expediente** — menos exposición y *mejores* respuestas (menos ruido, M2).
- **Agrega en vez de detallar** — totales y tendencias en lugar de registros individuales.
- **Usa el entorno corporativo** si trabajas con datos sensibles a menudo.
- **Higiene** — borra chats delicados; revisa knowledge (M3) y memoria (M4): lo que persiste, persiste.

Comparte **lo mínimo necesario**. No es solo privacidad: casi siempre mejora la calidad del resultado.

Cuando el riesgo cambia de naturaleza

Todo lo anterior asumía que **tú** decides qué enviar. Con connectors (M3) y agentes (M6), esa premisa se rompe.

- **Ya no controlas qué entra al contexto** — si le das tu correo, no elegiste tú qué mensajes se procesan.
- **Puede actuar hacia afuera** — propagar un dato sensible sin que lo veas.
- **Inyección de prompt indirecta** — datos no confiables + capacidad de actuar = el escenario más peligroso del curso.

OBLIGATORIO, NO OPCIONAL
Mínimo privilegio · humano en el bucle para lo irreversible · no encadenes lectura no confiable con escritura · revisa permisos periódicamente.

Cuanta más autonomía le das, menos control tienes sobre qué datos toca. **La autonomía es una decisión de privacidad**, no solo de productividad.

4

TEMA 4

Mantenerse actualizado sin volverse loco

Lo que cambia rápido es la superficie. Lo que aprendiste son los cimientos.

¿Esto cambia algo de lo que hago mañana?

SUELE SER SEÑAL	SUELE SER RUIDO
Documentación y notas de versión del producto que usas	"10 prompts que te harán millonario"
Cambios en capacidades (modalidad, contexto, herramientas)	Cambios menores de nombre o interfaz
Cambios en políticas de datos	Predicciones a 5 años
Casos reales de tu sector, con límites	Demos sin contexto ni verificación
Investigación sobre límites y evaluación	"La IA acabará con [profesión]"

Si la respuesta a la pregunta filtro es **no**, puedes leerlo por curiosidad — pero no es una tarea pendiente. La mayoría del contenido de IA no pasa este filtro.

Un sistema pequeño y repetible

- **1-2 fuentes primarias**, no veinte: la doc de lo que realmente usas.
 - **Ritmo fijo**: media hora al mes rinde más que 30 min diarios de hilos.
 - **Aprende haciendo**: una hora probando enseña más que diez leyendo.
-
- **Ten un problema pendiente**: sin esa lista, las novedades pasan de largo.
 - **Aprende en comunidad**: un grupo pequeño filtra mejor que cualquier algoritmo.
 - **Revisa tus prácticas**: quizá das rodeos que ya no hacen falta.

PERMISO EXPLÍCITO

No tienes que probar todas las herramientas nuevas. Elegir una y usarla bien vale más que saltar entre cinco. La ventaja no está en conocer la última novedad, sino en tener criterio y método sobre una que dominas.

Lo que seguirá siendo cierto en tres años

M1	Los modelos predicen; no consultan la verdad → siempre habrá que verificar lo que importa
M2	El contexto es el recurso escaso → lo que le das determina lo que obtienes
M3	Las herramientas tapan agujeros conocidos → elegir bien es aplicar lo que sabes
M4	El método vence al truco → especificar, iterar y verificar
M5	La capacidad se recombina → lo nuevo son combinaciones de lo conocido
M6	A más autonomía, más verificación → delegar acciones no delega responsabilidad
M7	Tú eres el responsable → firmas tú, no la herramienta

CIERRE DEL CURSO

Tu criterio es el producto

Empezamos preguntando **cómo piensa un modelo** y terminamos preguntando **cómo piensas tú al usarlo**. Ese es el arco completo.

LOS SIETE MÓDULOS EN UNA IDEA

La IA es un colaborador **extraordinariamente capaz** y **estructuralmente poco fiable**. Capaz, porque hace en segundos lo que exigía horas. Poco fiable no por estar mal hecha, sino por su naturaleza: **predice, no sabe**. Trabajar bien con ella es explotar lo primero sin olvidar lo segundo.

Y LO MÁS PRÁCTICO DE TODO

Empieza pequeño. Elige *un* caso del M5 que resuelva un dolor real de tu semana, aplícale el método del M4 y el criterio de hoy. Un caso bien resuelto enseña más —y convence más a tu equipo— que veinte experimentos a medias.

RESUMEN DEL MÓDULO 7

Los 4 temas, de un vistazo

#	TEMA	IDEA CENTRAL	PARA LLEVAR
1	Plausible ≠ correcto	El error y el acierto se producen igual	7 señales de alarma; verifica según el riesgo
2	Sesgos	Desviación sistemática, por tanto compensable	Abogado del diablo por defecto
3	Privacidad	Lo que escribes sale de tu equipo	Minimiza y anonimiza; lee tu política
4	Estar al día	Cambia la superficie, no los cimientos	Pocas fuentes, ritmo fijo, aprende haciendo

Las herramientas de hoy serán viejas pronto. Lo que no caduca es saber **qué tipo de caso es cada tarea, dónde va a fallar, cuánto verificar y qué no compartir**. Eso es criterio — y es tuyo.